

21. 고유값 분해와 특잇값 분해의 응용

1) Machine Learning과 Symmetric Positive (Semi-)Definite Matrix

- $A^T A$ 는 inner product로 계산된 샘플 간의 유사도를 나타낸다.

$$A = \begin{bmatrix} s_1 & s_2 & \dots & s_n \end{bmatrix} \quad A^T A = \begin{bmatrix} s_1^T & s_1^T & \dots & s_1^T \\ s_2^T & s_2^T & \dots & s_2^T \\ \vdots & \vdots & \ddots & \vdots \\ s_n^T & s_n^T & \dots & s_n^T \end{bmatrix} \begin{bmatrix} s_1 & s_2 & \dots & s_n \end{bmatrix} = \begin{bmatrix} s_1^T s_1 & s_1^T s_2 & \dots & s_1^T s_n \\ s_2^T s_1 & s_2^T s_2 & \dots & s_2^T s_n \\ \vdots & \vdots & \ddots & \vdots \\ s_n^T s_1 & s_n^T s_2 & \dots & s_n^T s_n \end{bmatrix}$$

샘플 간의 유사도 전부 도출 가능

s_1 과 s_1 관계
 s_1 과 s_2 관계

- AA^T 는 inner product로 계산된 특성 간의 유사도를 나타낸다.

$$A = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix} \quad AA^T = \begin{bmatrix} f_1 & f_1 & \dots & f_1 \\ f_2 & f_2 & \dots & f_2 \\ \vdots & \vdots & \ddots & \vdots \\ f_n & f_n & \dots & f_n \end{bmatrix} \begin{bmatrix} f_1^T & f_2^T & \dots & f_n^T \end{bmatrix} = \begin{bmatrix} f_1 f_1^T & f_1 f_2^T & \dots & f_1 f_n^T \\ f_2 f_1^T & f_2 f_2^T & \dots & f_2 f_n^T \\ \vdots & \vdots & \ddots & \vdots \\ f_n f_1^T & f_n f_2^T & \dots & f_n f_n^T \end{bmatrix}$$

특성 간의 유사도 (관계) 전부 도출 가능

f_2 와 f_1 관계
 f_n 과 f_1 관계


2) Low-Rank Approximation of a Matrix

- Matrix $A \in R^{m \times n}$ 의 SVD는 다음과 같이 나타낼 수 있었다.

$$A = U \Sigma V^T = \sum_{\lambda=1}^n \sigma_{\lambda} u_{\lambda} v_{\lambda}^T$$

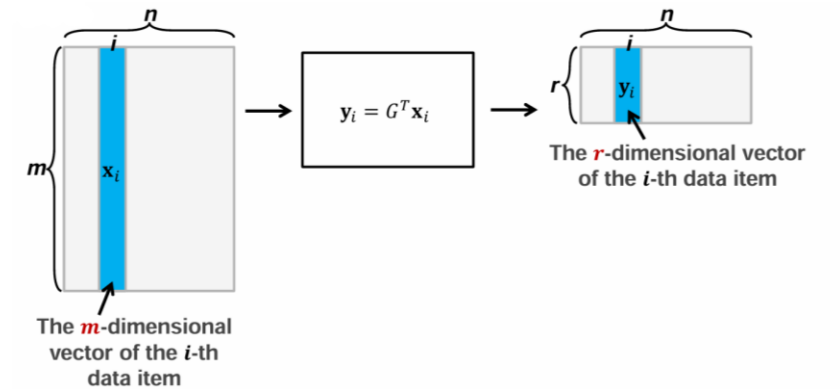
- A 를 낮은 차원으로 근사하고 싶다면 다음과 같이 원하는 차원까지만 더해주면(선택해주면) 된다.

$$\hat{A}_r = \sum_{\lambda=1}^r \sigma_{\lambda} u_{\lambda} v_{\lambda}^T$$



3) Dimension-Reducing Transformation

- 다음과 같이 matrix $X \in R^{m \times n}$ 의 차원을 linear transformation $G: x \in R^m \mapsto y \in R^r (r < m)$ 로 줄일 수 있다.



- $G \in R^{m \times r}$ 의 column이 orthonormal할 때, 샘플(A의 column) 간의 유사도를 가장 잘 보존하는 G 는 SVD로 구해진 U 의 column으로 이루어진다.

$$\hat{G} = U_r = [u_1 \ u_2 \ \dots \ u_r]$$

$$Y = \hat{G}^T X = U_r^T U \Sigma V^T = \Sigma_r V_r^T$$